


機器學習 10 大經典圖表 與模型評估深度解析手冊

一份專為資料科學家設計的視覺化與計量評估理論指南



專案團隊製作

發行時間：2026 年 6 月

官方開源儲存庫

目錄

1	引言：機器學習與數據視覺化的共生關係	2
2	線性迴歸擬合線 (Linear Regression Fit)	2
2.1	數學模型與參數估計	2
2.2	擬合線圖表的診斷意義	2
3	機器學習決策邊界 (Decision Boundary)	2
3.1	非線性邊界與核函數	3
4	混淆矩陣熱力圖 (Confusion Matrix)	3
4.1	矩陣定義與構成	3
4.2	熱力圖的優勢	3
5	ROC 曲線與 AUC (ROC Curve & AUC)	3
5.1	數學推導	4
5.2	TikZ 向量圖：ROC 曲線繪製	4
6	精確度-召回率曲線 (Precision-Recall Curve)	4
6.1	精準度與召回率的權衡	4
7	K-Means 聚類分析 (K-Means Clustering)	5
7.1	算法優化目標	5
7.2	聚類分布圖的觀察重點	5
8	特徵重要性條形圖 (Feature Importance)	5
8.1	計算指標：Gini 重要度	5
9	模型學習曲線 (Learning Curve)	5
9.1	學習曲線判定準則	5
10	預測值與殘差分析圖 (Residuals Plot)	6
10.1	殘差定義	6
11	PCA 降維 2D 投影圖 (PCA Projection)	6
11.1	協方差矩陣與特徵值分解	6
12	總結與最佳實踐	6

1 引言：機器學習與數據視覺化的共生關係

在現代人工智慧與資料科學領域中，機器學習模型常常被冠以「黑盒子 (Black Box)」的稱號。一個擁有數百萬甚至數十億參數的深度神經網路或整合決策樹模型，其內部決策邏輯之複雜，往往超出了人類直覺的理解範疇。然而，模型的部署與落地需要信任，信任則建立在可解釋性與嚴格的效能評估之上。

數據視覺化 (Data Visualization) 在此時扮演了溝通「數值指標」與「人類認知」的重要橋樑。本手冊將深度剖析在統計機器學習與深度學習中，最常使用的 10 種經典圖表，從底層數學公式出發，詳細講解它們的繪製原理、解讀方法、診斷特徵以及常見的誤區。

2 線性迴歸擬合線 (Linear Regression Fit)

線性迴歸是監督式學習中最基礎且最重要的統計學模型。在二維特徵空間中，線性迴歸旨在尋找一條最優直線來描述自變量 X 與因變量 Y 之間的因果關係。

2.1 數學模型與參數估計

給定觀測數據集 $\mathcal{D} = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$ ，一元線性迴歸的模型表達式為：

$$y_i = wx_i + b + \epsilon_i \quad (1)$$

其中 w 為斜率權重， b 為截距偏置， ϵ_i 為隨機誤差。我們假設隨機誤差服從獨立同分布的正態分布： $\epsilon_i \sim \mathcal{N}(0, \sigma^2)$ 。

為了求解最優參數 w 與 b ，我們採用最小二乘法 (Ordinary Least Squares, OLS)，其目標是最小化殘差平方和 (Residual Sum of Squares, RSS)：

$$J(w, b) = \sum_{i=1}^n (y_i - (wx_i + b))^2 \quad (2)$$

對 w 與 b 分別求偏導數並令其為 0，可解得解析解：

$$w = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad (3)$$

$$b = \bar{y} - w\bar{x} \quad (4)$$

2.2 擬合線圖表的診斷意義

擬合線圖表通常同時呈現「散點分布」與「擬合直線」。

- **數據集趨勢度量**：觀測散點與擬合線的貼合程度，反映了線性關係的強弱。
- **異常值 (Outliers) 識別**：偏離擬合直線極遠的樣本點可能是測量誤差或特殊極端事件，會對最小二乘法產生極大的拉扯（高槓桿點）。

3 機器學習決策邊界 (Decision Boundary)

在分類任務中，機器學習模型的基本任務是在特徵空間中劃分不同的區域。不同區域的交界處，即為決策邊界。

3.1 非線性邊界與核函數

以支持向量機（Support Vector Machine, SVM）為例，當面對非線性可分的數據時，我們藉由核函數（Kernel Function）將低維特徵映射到高維空間：

$$f(x) = \text{sign} \left(\sum_{i=1}^n \alpha_i y_i K(x_i, x) + b \right) \quad (5)$$

常見的徑向基核函數（RBF Kernel）定義為：

$$K(x_i, x) = \exp(-\gamma \|x_i - x\|^2) \quad (6)$$

在二維投影空間中繪製決策邊界，能幫助我們直觀評估以下特徵：

- **過擬合 (Overfitting)**: 如果邊界極度扭曲、碎裂，將每一個噪聲點都包圍起來，說明模型複雜度過高，泛化能力差。
- **欠擬合 (Underfitting)**: 如果特徵本身呈環形分佈，而決策邊界呈一條單純的直線，表明模型表達能力不足。

4 混淆矩陣熱力圖 (Confusion Matrix)

混淆矩陣是衡量分類器在各個類別上預測精準度的最直觀工具，尤其是在多分類（Multi-class）場景。

4.1 矩陣定義與構成

對於一個二分類任務，混淆矩陣由四個基本指標構成：

表 1: 二分類混淆矩陣標準結構

	預測為正 (Predicted Positive)	預測為負 (Predicted Negative)
真實為正 (Actual Positive)	真陽性 (True Positive, TP)	偽陰性 (False Negative, FN)
真實為負 (Actual Negative)	偽陽性 (False Point, FP)	真陰性 (True Negative, TN)

4.2 熱力圖的優勢

當分類類別數（例如 ImageNet 中的 1000 分類）極多時，數值矩陣會變得極其難以閱讀。熱力圖（Heatmap）將矩陣內的數值映射成顏色深淺：

- **對角線分析**: 如果對角線顏色深（數值大），說明分類器的整體準確度極高。
- **混淆重災區定位**: 若非對角線上的某個格子顏色異常深，例如「真實貓」常被「預測為狗」，這能明確指引特徵工程優化的方向。

5 ROC 曲線與 AUC (ROC Curve & AUC)

受試者工作特徵曲線（Receiver Operating Characteristic Curve）是評估二分類模型在所有可能判決閾值（Thresholds）下性能的黃金標準。

5.1 數學推導

ROC 曲線的橫軸為偽陽性率（False Positive Rate, FPR），縱軸為真陽性率（True Positive Rate, TPR / Recall）：

$$FPR = \frac{FP}{FP + TN} = \frac{\text{偽陽性}}{\text{全體真實負樣本}} \quad (7)$$

$$TPR = \frac{TP}{TP + FN} = \frac{\text{真陽性}}{\text{全體真實正樣本}} \quad (8)$$

當我們移動分類閾值 $\theta \in [0, 1]$ 時，TPR 與 FPR 會相應改變，在二維空間軌跡化出一條曲線。

5.2 TikZ 向量圖：ROC 曲線繪製

以下為手冊原生編譯生成的經典 ROC 曲線與隨機基準線對比圖：




图 1: 典型的 ROC 曲線與隨機分類器之性能比較

6 精確度-召回率曲線 (Precision-Recall Curve)

在數據集極度不平衡（Imbalanced Dataset）的場景下，如信用卡欺詐檢測（正樣本僅佔 0.1%），ROC 曲線可能會給出過於樂觀的評估，此時 Precision-Recall (PR) 曲線是更佳的評估利器。

6.1 精準度與召回率的權衡

$$\text{Precision (精確度)} = \frac{TP}{TP + FP} \quad (9)$$

$$\text{Recall (召回率)} = \frac{TP}{TP + FN} \quad (10)$$

PR 曲線展現了當召回率提升時，精確度下降的幅度。若一條 PR 曲線能向右上角（1.0, 1.0）極度逼近，說明模型在極低的偽陽性率下依然能保有高檢出率。

7 K-Means 聚類分析 (K-Means Clustering)

K-Means 是一種經典的非監督式學習算法，旨在將無標籤的點集自動劃分為 K 個空間簇（Clusters）。

7.1 算法優化目標

K-Means 的目標是最小化簇內平方誤差和（Within-Cluster Sum of Squares, WCSS）：

$$WCSS = \sum_{j=1}^K \sum_{x_i \in C_j} \|x_i - \mu_j\|^2 \quad (11)$$

其中 μ_j 是第 j 個簇的質心（Centroid）。

7.2 聚類分布圖的觀察重點

- **聚類邊界**：各聚類之間的重疊程度。若邊界極清晰，說明特徵選擇優良。
- **質心定位**：質心是否確實處於高密度核心區域，可用於偵測聚類算法是否收斂至局部極小值。

8 特徵重要性條形圖 (Feature Importance)

在複雜機器學習模型中，我們常需要知道「是哪些變量主導了預測」。

8.1 計算指標：Gini 重要度

在隨機森林（Random Forest）中，特徵 X_j 的重要度通常基於基尼不純度（Gini Impurity）的總減少量來計算：

$$\text{Gini}(D) = 1 - \sum_{k=1}^K p_k^2 \quad (12)$$

條形圖（Bar Chart）按重要度從高到低排列特徵，能指引特徵剪枝與模型精簡（Feature Selection）。

9 模型學習曲線 (Learning Curve)

學習曲線是診斷模型「偏差-方差權衡（Bias-Variance Tradeoff）」的經典臨床工具。

9.1 學習曲線判定準則

其繪製訓練集得分（Training Score）與驗證集得分（Validation Score）隨訓練樣本數量增加的演變：

- **高偏差 (欠擬合)**：兩條曲線在低準確度水平極快靠攏並趨於平緩。增加數據無法改善性能。
- **高方差 (過擬合)**：訓練集得分維持極高，但驗證集得分遠低於訓練集，兩者存在巨大鴻溝（Gap）。此時增加數據有助於閉合該間距。

10 預測值與殘差分析圖 (Residuals Plot)

迴歸模型的效能好壞不只看 R^2 或 RMSE 等單一指標，更需要透過殘差分析來確認模型的基本假設。

10.1 殘差定義

$$e_i = y_i - \hat{y}_i \quad (13)$$

在殘差分析圖中：

- **同方差性 (Homoscedasticity)**：殘差應當隨機、均勻地分布在 $e = 0$ 基準線上下，無任何可辨識的規律（如漏斗狀）。
- **非線性特徵外溢**：若殘差呈明顯的二次曲線彎曲，意味著自變量與因變量之間存在未被捕捉的非線性高階特徵。

11 PCA 降維 2D 投影圖 (PCA Projection)

主成分分析（Principal Component Analysis, PCA）是最主流的線性降維算法，將高維特徵投影至最大方差方向。

11.1 協方差矩陣與特徵值分解

給定零均值化的數據矩陣 X ，其協方差矩陣為：

$$\Sigma = \frac{1}{n} X^T X \quad (14)$$

我們對 Σ 進行特徵值分解（Eigenvalue Decomposition）：

$$\Sigma v_i = \lambda_i v_i \quad (15)$$

保留前兩個最大特徵值對應的特徵向量 v_1, v_2 ，即可將高維數據點降維投影至二維平面：

$$Z = X[v_1, v_2] \quad (16)$$

在 PCA 投影圖中，每個軸標記出其所解釋的變異量百分比（如 PC1: 42%），我們以此圖評估高維數據點在投影空間中的自然聚類流形。

12 總結與最佳實踐

機器學習模型的評估不是單維度的。在實際專案開發中，優秀的資料科學家應該動態結合這 10 種圖表：

1. 數據準備階段使用 **PCA 降維圖** 觀察流形。
2. 訓練初期使用 **學習曲線** 診斷擬合狀態。
3. 迴歸任務必須輔以 **殘差分析** 與 **擬合線圖**。
4. 分類任務則需結合 **混淆矩陣**、**ROC** 與 **PR 曲線** 來做出最符合業務效益的閾值抉擇。